

山东大学计算机科学与技术学院

大数据分析实践课程实验报告

学号: 202300130098	姓名: 马浩鑫	班级: 23 级数据		
实验题目: 二、数据质量实践				
实验学时: 2 课时	实验日期:			
实验目标: 本次实验主要围绕宝可梦数据集进行分析, 考察在拿到数据后如何对现有的数据进行预处理清洗操作, 建立起对于脏数据、缺失数据等异常情况的一套完整流程的认识。				
实验描述: 1. 实验环境 python3.9, jupyter notebook 2. 数据集 Pokeman Dataset: 721 Pokemon, including their number, name, first and second type, and basic stats: HP, Attack, Defense, Special Attack, Special Defense, and Speed http://storage.amesholland.xyz/Pokemon.csv 3. 分析数据 (1) 数据总览				
<pre>[13] # Name Type 1 Type 2 Total HP Attack Defense Sp. Atk \ 0 1 Bulbasaur Grass Poison 318 45 49 49 65 1 2 Ivysaur Grass Poison 405 60 62 63 80 2 3 Venusaur Grass Poison 525 80 82 83 100 3 3 VenusaurMega Venusaur Grass Poison 625 80 100 123 122 4 4 Charmander Fire NaN 309 39 52 43 60 Sp. Def Speed Generation Legendary 0 65 45 1 FALSE 1 80 60 1 FALSE 2 100 80 1 FALSE 3 120 80 1 FALSE 4 50 65 1 FALSE 数据总行数: 810 总列数: 13</pre>				

(2) 统计缺失行

1. 空行统计（含伪空行）：
 - 空行总数：3行
 - 空行索引：[408, 808, 809]
2. 无定义行统计（属性值为'undefined'）：
 - 无定义行数量：2行
 - 无定义行索引：[806, 771]

(3) 检测完全重复行

1. 完全重复行数量：12
 - 重复行索引：[14, 15, 21, 23, 184, 185, 186, 187, 806, 807, 808, 809]
 - 重复行分组详情（按宝可梦编号#聚合，符合指导书分析逻辑）：


编号11的重复行（共2行）：

#	Name	Type 1	Type 2	Total	HP	Attack
14	11	Metapod	Bug	NaN	205	50
15	11	Metapod	Bug	NaN	205	50


编号168的重复行（共4行）：

#	Name	Type 1	Type 2	Total	HP	Attack
184	168	Ariados	Bug	Poison	390	70
185	168	Ariados	Bug	Poison	390	70
186	168	Ariados	Bug	Poison	390	70
--	--	--	--	--	--	--

(4) 列异常值分析（字段类型），以 type1、type2 为例



(5) 列异常值分析（数据类型），以 attack 值为例



结论分析：

基于宝可梦数据集（721 只宝可梦，含编号、类型、基础属性等），发现以下 4 类数据质量问题：

1. 无意义空行：数据集底部存在多行为 NaN 的空行（指导书提及“最后两行无意义”），需删除避免统计偏差；Type 2（第二属性）缺失属合理情况（部分宝可梦无第二属性），无需填充。

2. 重复值：存在完全重复行（如 Ariados 重复记录），源于录入错误，会高估样本占比，需保留首行删除其余。

属性异常：

3. 分类属性：Type 2 含“273”等非标准类型，Legendary（是否传说）存非布尔值，属录入错误；

数值属性：Attack（攻击力）有过高值，部分为 Mega 进化合理属性，需排除非进化错误值；Generation（世代）存超 1-6 范围值，需修正。

4. 列混淆：Generation 与 Legendary 值置换（如世代填布尔值、是否传说填整数），致分析逻辑失效，需按字段规则交换修复。